

# 手勢辨識專題 — 韌體端進度報告

報告期間：2026/09/08 – 09/11 報告人：Kevin（韌體 / 部署端） 分工：訓練與模型匯出由 Johnson 負責，本報告涵蓋韌體端與實機驗證

## 摘要

09/08 的起點是「模型燒錄進開發板後完全不畫任何 bounding box」。四天內定位出**三個獨立的根因**，修復其中兩個屬於韌體端的問題，並以一組對照實驗確認修復有效。

| # | 根因                                 | 責任端 | 狀態              |
|---|------------------------------------|-----|-----------------|
| 1 | 96×96 模型本身不可用                      | 訓練  | 已放棄 96，全案改用 192 |
| 2 | 韌體前處理幾何失真（水平壓扁 25%）                | 韌體  | 已修復並驗證          |
| 3 | 訓練集缺乏尺度變化（類別內 P90/P10 僅 1.1–1.8 倍） | 訓練  | 已量化並交付訓練端       |

**韌體端工作至此結案**。剩餘的辨識錯誤已定位在訓練資料，韌體無法再改善。

## 一、起點與問題描述

硬體為 Seeed Grove Vision AI Module V2（Himax WiseEye2，Cortex-M55 + Ethos-U55 NPU），執行 YOLOv8n 的 11 類手勢辨識（數字 0–9 與手勢 B）。

初始症狀：模型載入成功、每幀推論都回報 `invoke pass`，但輸出的 bounding box 數恆為 0。

## 二、方法

由於中間環節多（相機 → 縮放 → 量化 → NPU → 反量化 → 解碼 → NMS），採取**逐項隔離、每一項都要有可觀測證據**的做法，而非依賴推測。

關鍵手法是在韌體中加入一段診斷程式，把**實際送進 NPU 的輸入張量**（ $192 \times 192 \times 3 = 110,592$  bytes）以 base64 經 UART 傳回 PC 並還原成圖片。

這一步把「相機、縮放、RGB 通道順序、uint8→int8 轉換」四個環節一次排除 —— 還原出來的是一隻清晰、顏色正確的手。數值統計無法區分「正確縮小的圖」與「錯位的垃圾」，必須把影像還原出來看。

同時修正 Himax 原廠範例中的數個缺陷：

- `cv_yolov8n_ob_init()` 失敗時 `return false`，而 `false = 0` = 成功碼，且呼叫端未接回傳值
- `anchor` 數量不符時靜默 `return`，不留任何訊息
- `interpreter` 為 `null` 時整段推論被跳過且無輸出

這些缺陷本身不是根因，但它們讓真正的錯誤無法被觀察到。

### 三、發現一：96×96 模型不可用

在**韌體程式碼、相機、拍攝環境完全相同**的條件下，只切換輸入尺寸與對應模型：

|          | 96 模型   | 192 模型    |
|----------|---------|-----------|
| 最高信心度    | 7%      | 90%       |
| 通過門檻的幀數  | 0 / 157 | 143 / 247 |
| 實際輸出的框   | 0       | 140       |
| 輸入張量亮度均值 | 81      | 84        |

兩邊的輸入影像還原後品質一致（亮度僅差 3），**輸入路徑不是變因**。

結論：96 那次訓練產出的模型本身不可用。全案改採 192×192。

此結果同時一次性驗證了整條鏈路：開機、NPU 初始化、模型載入、記憶體配置、相機、縮放、通道順序、量化轉換、輸出格式偵測、反量化、DFL 解碼、面積過濾、NMS。

### 四、發現二：韌體前處理的幾何失真

#### 問題

|        |             |          |
|--------|-------------|----------|
| 訓練影像   | 1440 × 1440 | 正方形      |
| 相機 raw | 320 × 240   | 4:3      |
| 模型輸入   | 192 × 192   | ← 原本直接拉伸 |

原始程式將 4:3 直接拉伸為 1:1，**水平方向被額外壓縮 25%**（寬  $192/320 = 0.600$ ，高  $192/240 = 0.800$ ）。而 ultralytics 訓練與推論皆採用 letterbox（等比縮放後補邊），模型從未見過橫向壓扁的手。

#### 佐證

原始素材混合兩種來源（1920×1080 與 1440×1440），抽出的訓練圖皆為 1440×1440。比對同類別、不同來源影片的**標註框長寬比**：

| 類別 | 16:9 來源 | 1:1 來源 | 比值   |
|----|---------|--------|------|
| 0  | 0.811   | 0.849  | 1.05 |
| 1  | 0.520   | 0.502  | 1.04 |
| 5  | 1.069   | 1.083  | 1.01 |
| 9  | 1.088   | 1.091  | 1.00 |
| B  | 3.382   | 3.400  | 1.01 |

若訓練圖是壓扁而成，16:9 來源的長寬比應為原本的 0.5625 倍，比值會落在 1.78 附近。實測為 1.00–1.15，證實訓練圖是置中裁切、幾何忠實。

失敗類別的分布本身也是獨立佐證：垂直方向的手勢（0 拳、1 食指、2 V、3 三指）正常，水平張開的手勢（4、5、7、8、9）全數失敗——拇指是唯一往水平方向伸出的手指。

修復與效果

實作 letterbox（等比縮放 + 補灰邊 114）：

| session | 修復 | 偵測筆數                 | 出現類別數         | cls4          |
|---------|----|----------------------|---------------|---------------|
| 前四場     | 前  | 236 / 334 / 199 / 67 | 9 / 6 / 6 / 3 | 0 / 0 / 0 / 0 |
| 16:45   | 後  | 540                  | 10            | 118           |

cls4 由四場全數掛零變為 118 筆（最高信心度 93%），類別涵蓋由 3 類回復至 10 類。

五、發現三：訓練集缺乏尺度變化（最關鍵）

量測

自行撰寫工具量測訓練集標註框的分布：

| 類別 | 框寬佔畫面 | 類別內 P90/P10 |
|----|-------|-------------|
| 0  | 60.2% | 1.27×       |
| 1  | 53.1% | 1.12×       |
| 2  | 62.9% | 1.51×       |
| 3  | 65.1% | 1.75×       |
| 4  | 79.7% | 1.13×       |
| 5  | 97.0% | 1.18×       |
| 6  | 95.1% | 1.22×       |
| 7  | 84.2% | 1.16×       |
| 8  | 95.1% | 1.46×       |
| 9  | 92.3% | 1.15×       |
| B  | 84.4% | 1.42×       |

具備 scale augmentation 的資料集，類別內 P90/P10 通常落在 3–10 倍；此處全數為 1.1–1.8 倍。

亦即：模型看過的每一張「5」，手的大小幾乎相同。它沒有機會學到「不論手多大，五根手指就是 5」。

### 這一組數字解釋了三個先前無法理解的現象

#### (1) cls5 幾乎從未被偵測到（七場測試合計僅 8 筆）

訓練時 cls5 的框寬中位數為 97%（手橫跨整張影像）；實機以膚色遮罩量測，手的水平跨幅僅 27–37% 畫面寬。相差近三倍。

#### (2) 失敗類別恰好是「寬」的那些

正常：0（寬 60%） 1（53%） 2（63%） 3（65%）  
失敗：4（80%） 5（97%） 6（95%） 7（84%） 8（95%） 9（92%）

分界落在框寬 65% 與 80% 之間 —— 與「拇指」「手指數量」等語意分類無關，是尺度。

#### (3) 同一顆模型每場測試結果都不同

2026/09/10，同一顆模型、同一份韌體、30 分鐘內四場測試：

| session | 主導類別     | cls0      | cls5     | cls6      |
|---------|----------|-----------|----------|-----------|
| 19:46   | cls4 42% | 16        | 4        | 0         |
| 19:52   | cls2 27% | 10        | 1        | <b>13</b> |
| 20:02   | cls4 32% | <b>29</b> | <b>0</b> | 3         |
| 20:14   | cls2 35% | <b>1</b>  | 3        | 2         |

唯一變因是手擺放的位置與距離。

## 六、韌體改善：center-crop 取代 letterbox

letterbox 雖修正了幾何，但帶來兩個新問題：

- 192×192 中有 48 列（**25% 的畫面**）是訓練時從未出現過的灰色填充
- 有效影像僅 192×144，手的垂直解析度被壓至 144 px

改採 center-crop：自 320×240 取中央 **240×240** 正方形，再縮放至 192×192。

|         | letterbox | center-crop          |
|---------|-----------|----------------------|
| 有效影像    | 192×144   | <b>192×192</b>       |
| 灰邊      | 48 列      | 無                    |
| 手的垂直解析度 | 144 px    | <b>192 px (+33%)</b> |
| 水平視野    | 100%      | 75%                  |

## 七、A→B→A 對照實驗（09/11）

### 實驗設計

先前的比較都是「跑一場、看結果」，但已證實同一設定下場次間變異極大，單場比較不可靠。因此採用 **ABA reversal design**：

同一時段連續完成三輪，**僅改動韌體的輸入模式一個參數**，模型、光線、距離、測試流程全部固定。第三輪回到 A，用以檢驗第一輪是否為偶然。

結果

| 輪次           | 模式驗證                | 畫面亮度  | 筆數  | 平均信心度 | ≥70% 佔比 |
|--------------|---------------------|-------|-----|-------|---------|
| R1 crop      | $x \in [40, 280]$ ✓ | 126.8 | 198 | 59.8% | 44%     |
| R2 letterbox | $x \in [0, 320]$ ✓  | 127.7 | 369 | 41.6% | 12%     |
| R3 crop      | $x \in [40, 280]$ ✓ | 125.8 | 200 | 57.7% | 36%     |

兩項控制：

- **光線**：三輪畫面亮度 126.8 / 127.7 / 125.8，差距小於 2
- **模式**：以輸出框的座標範圍反推驗證——center-crop 的框必然落在中央  $240 \times 240$  ( $x \in [40, 280]$ )，letterbox 則會超出。三輪皆符合預期

判讀

|                      |                |
|----------------------|----------------|
| 兩輪 crop 彼此差距         | = 2.1 個百分點     |
| crop 平均 vs letterbox | = 17.1 個百分點    |
|                      | ↑ 為輪內變異的 8.2 倍 |

效果遠大於雜訊，**center-crop 確認有效**。

同時進行逐幀人工核對（每輪抽樣 10 幀比對實際手勢）：

|              | 準確率  |
|--------------|------|
| R1 crop      | 4/10 |
| R2 letterbox | 2/10 |
| R3 crop      | 4/10 |

兩輪 crop 完全一致，方向與信心度指標相符。

|                                                                                                    |
|----------------------------------------------------------------------------------------------------|
| 限制說明：10 幀樣本下 40% vs 20% 以 Fisher 精確檢定 $p = 0.42$ ，單就準確率而言未達顯著。主要證據為信心的可重現性（8.2 倍比值），逐幀準確率為方向一致的佐證。 |
|----------------------------------------------------------------------------------------------------|

八、韌體端的能力邊界

crop 與 letterbox 兩種模式都有過度觸發的類別，只是位置不同：

|       | crop           | letterbox |
|-------|----------------|-----------|
| 過度觸發  | cls2 43% / 34% | cls3 32%  |
| 完全未出現 | cls3、cls4      | cls10 (B) |

crop 使緊湊的手勢 (0/1/6/B) 改善，但張開的手勢 (3/4/5) 外緣被裁切，反而變差。

**更換前處理只是將分界線移動到別處，無法消除分界線本身。** 分界線的位置由訓練資料的尺度分布決定，屬訓練端。

## 九、方法論上的三項修正

過程中曾下過三個後來證實不成立的結論，一併記錄：

### (1)「手往後退比較準」—— 撤回

09/09 依據單一場測試 (16 個取樣點) 所下的結論。後續四場合併觀察後發現場次間變異過大，單場比較不成立。正確的敘述是：模型對「手放多遠」比對「比什麼手勢」更敏感。

### (2)「以平均信心度比較模型版本」—— 方法錯誤

實測發現：信心度較低的那一場，準確率反而是兩倍。原因是模型崩潰時會輸出「滿版框 + 單一類別」，產生虛假的高信心度。此後改以逐幀人工核對為準。

### (3)「模型以框大小作為分類捷徑」—— 未能證實

以訓練集典型框面積對實機預測框面積求相關性，三場得到 +0.68 / +0.60 / -0.49，不一致且未達顯著 (n = 6-7，p > 0.09)。此機制不予採信。

## 十、產出與現況

### 韌體端（已完成）

| 項目                     | 狀態                     |
|------------------------|------------------------|
| 幾何失真（水平壓扁 25%）         | ✓ 修復                   |
| 灰邊與解析度浪費               | ✓ center-crop，經對照實驗證實  |
| Himax 原廠缺陷 ×5          | ✓ 修復                   |
| 輸出格式自動偵測（Layout A / B） | ✓ 換模型免改程式、免重編          |
| PC 端畫框過濾缺陷             | ✓ 修復（先前有 69% 的偵測被靜默丟棄） |

### 自行開發的工具

| 工具                                     | 用途             |
|----------------------------------------|----------------|
| 輸入張量 base64 傾印                         | 還原模型實際看到的畫面    |
| <code>check_label_scale.py</code>      | 量測訓練集標註框的尺度分布  |
| <code>check_scale_invariance.py</code> | 量測模型對物件大小的敏感度  |
| <code>switch_input_size.py</code>      | 一個指令切換全鏈路的輸入尺寸 |
| <code>capture_boot_log.py</code>       | 開機 log 擷取      |
| PC 端即時亮度 / 裁切範圍顯示                      | 控制實驗變因         |

### 已建立的評估規範

先前使用的「類別出現筆數、平均信心度、最高信心度」三項指標，在 09/10 的測試中都會給出**相反**的結論，現已停用。

現行規範：依序比  $0 \rightarrow 1 \rightarrow \dots \rightarrow 9 \rightarrow B$ ，每個手勢停留 8-10 秒，關閉多幀投票，逐幀人工核對計算真實準確率，並記錄畫面亮度以確保可比性。任何改動的比較一律採  $A \rightarrow B \rightarrow A$  三輪。

## 十一、下一步

韌體端已無可改善之處，後續工作集中於訓練端：

| 優先序 | 項目                                             | 說明                                                  |
|-----|------------------------------------------------|-----------------------------------------------------|
| 1   | 釐清新增的 Sharpen 前處理                              | 訓練影像全部經過銳化、實機畫面沒有。此不一致在驗證集 mAP 上完全看不出來，會使後續所有指標失去意義 |
| 2   | 以 <code>check_scale_invariance.py</code> 量測新模型 | 直接量「手佔畫面比例」對辨識結果的影響，為目前最關鍵的指標                       |
| 3   | 逐類別 mAP                                        | 平均值會掩蓋 3/4/5/7/8/9 的崩潰                              |
| 4   | validation 改用 group split                      | 現行隨機切分可能造成資料洩漏，mAP 虛高                               |

訓練端已於 09/11 加入 `scale=0.7`、`translate=0.2`、`mosaic=1.0` 重新訓練，新模型完成後可直接燒錄驗證（韌體支援自動偵測，無須修改）。

---

## 附：資料保存

- 測試原始資料：`captures/session_2026091*/`（逐幀影像與 CSV，共 12 場）
- 對照圖：`Analysis/`
- 技術文件：`docs/`（交接文件 v3-v6、實機測試紀錄、訓練回饋）